MACHINE LEARNING CANVAS

Designed for: MiBici-P2 | Designed by: Roberto Robles – Equipo 52 | Date: 16/oct/26 | Iteration: 1

PREDICTION TASK



What is the type of task?
Which entity are predictions made on?
What are the possible outcomes to predict?
When are outcomes observed?

Clasificación en 3 clases. Se debe predecir para cada estación y por cada hora: ¿en las próximas 3 horas estará normal, sin bicicletas o sin anclajes libres? Se sabe la respuesta 3 horas después, con los viajes registrados.

DECISIONS



How are predictions turned into actionable recommendations or decisions for the end-user? (Mention parameters of the process / application for this.)

Cada hora, se generará una lista de estaciones con alerta. El equipo de rebalanceo decide a cuáles mandar la camioneta (llevar o retirar bicicletas). Parámetro que se utilizará: qué tan sensible es la alerta (prudente o alarmista).

VALUE PROPOSITION



Who is the end beneficiary, and what specific pain points are addressed?
How will the ML solution integrate with their workflow, and through which user interfaces?

Los beneficiarios son los usuarios que hoy llegan y no hay bicicleta o no hay dónde dejarla. La Agencia Metropolitana de Servicios de Infraestructura para la Movilidad del Área Metropolitana de Guadalajara, al ser el proveedor del servicio, también se beneficia por mejorar el servicio y controlar su costo. Se entregaría como una lista o tablero por hora para el equipo de rebalanceo.

DATA COLLECTION



How is the initial set of entities and outcomes sourced (e.g., database extracts, API pulls, manual labeling)?
What strategies are in place to update data continuously while controlling cost and maintaining freshness?

Con el programa dataset.py se descargan automáticamente los datos abiertos de la página de MiBici y se guardan en un solo archivo limpio (Parquet). Se actualiza cada mes. El manifiesto detecta archivos que MiBici vuelve a publicar.

DATA SOURCES



Where can we get data on entities and observed outcomes? (Mention internal and external database tables or API methods.)

Se obtienen los viajes de MiBici (142 archivos, 39,078,984 viajes) desde diciembre de 2014 hasta el 30 de septiembre de 2026, y la nomenclatura de estaciones (capacidad y ubicación). A la fecha no existe inventario de bicicletas por estación.

IMPACT SIMULATION

What are the cost/gain values for (in)correct decisions?
Which data is used to simulate pre-deployment impact?
What are the criteria for deployment?
Are there fairness constraints?

Se compara la afectación a la calidad del servicio por una falla no atendida contra el costo de un viaje de la camioneta que resulta en vano. La simulación se hizo con abril a septiembre de 2026, meses que el modelo no vio al entrenar. Criterio: superar al modelo base (F1 0.405) y acordar con el operador qué tan sensible debe ser la alerta. Tenemos restricciones de información porque no sabemos en tiempo real cuántas bicicletas y anclajes hay disponibles en cada estación.

MAKING PREDICTIONS

Are predictions made in batch or in real time?
How frequently?
How much time is available for this (including featurization and decisions)?
Which computational resources are used?

Las predicciones (clasificación) se hacen por lotes cada hora, anticipando las próximas tres horas, para dar oportunidad de decidir al operador del servicio. El uso de recursos computacionales es bajo.

BUILDING MODELS

How many models are needed in production?
When should they be updated?
How much time is available for this (including featurization and analysis)?
Which computation resources are used?

Se usaron dos modelos: uno base (si a esa hora y día falló en 2 o más de las últimas 4 semanas, se predice falla) y un candidato con HistGradientBoosting. Se califican con recall, precision y F1. El modelo se reentrena cada mes con los datos nuevos; entrenarlo toma unos 5 minutos en una laptop.

FEATURES

What representations are used for entities at prediction time?
What aggregations or transformations are applied to raw data sources?

Se utilizaron representaciones por hora, día, mes, fin de semana, capacidad, ubicación, salidas y llegadas de las horas anteriores, y fallas en las últimas 4 semanas a la misma hora. Se agregan los viajes por estación y hora, y se suman las horas anteriores. Se unificaron los formatos de fecha y la codificación de los archivos.

MONITORING

Which metrics and KPIs are used to track the ML solution's impact once deployed, both for end-users and for the business?
How often should they be reviewed?

Sugerimos monitoreo mensual con indicadores de porcentaje de fallas anticipadas y porcentaje de alertas certeras por tipo. También horas con estaciones vacías o llenas y viajes en vano de la camioneta.

Version 1.2. Created by Louis Dorard, Ph.D. Licensed under a Creative Commons Attribution-ShareAlike 4.0 International License.
Please keep this mention and the link to ownml.co when sharing.